

Матрица tf-df —

Дистрибутивная семантика

Семантические анализаторы

Магистратура 1 курс

Что такое дистрибутивная семантика?

ДС - совокупность методов формального представления и дальнейшего исследования лексического значения слов с опорой на контексты их употребления в корпусе.

Дистрибутивная гипотеза

- Витгенштейн, Логико-философский трактат: Значение слова есть его употребление
- Фёрс: You shall know a word by the company it keeps!
- Харрис: дистрибутивная гипотеза о возможности выведения свойств языковых выражений путем исследования сочетаемости единиц низших уровней.
- Рубинштейн и Гуденаф: слова с близкими значениями употребляются в сходных контекстах
- Шютце и Педерсен: слова со сходными значениями встречаются с одними и теми же контекстными соседями (при условии достаточности контекстных данных)
- ...
- Значение слова выводимо из контекста.

Дистрибутивная гипотеза

Дистрибутивная гипотеза (общая формулировка): по меньшей мере некоторые аспекты лексического значения зависят от дистрибутивных свойств слова в контексте.

- **Сильная ДГ:** степень семантической близости двух выражений А и В есть функция близости контекстов употребления А и В; ДС есть количественный метод семантического анализа и построения лексических ресурсов
- **Слабая ДГ:** когнитивная теория, объясняющая вид и происхождение семантических представлений на основе дистрибуций слов в контекстах; мы понимаем незнакомые слова в тексте, опираясь на их окружение и экстралингвистический контекст. Возможно, эта особенность отражается в организации ментального лексикона.

Почему модели дистрибутивной семантики важны?

- СемП, строящиеся на основе языков семантических признаков (теория семантических примитивов А.Вежбицкой, Московская семиотическая школа и т.д.), имеют ограниченные возможности.
- Значение слова должно рассматриваться и с т.зр. его восприятия, это нечеткий объект, собеседники «распознают» значения слов в тексте по определенным критериям.
- Например, слово *цеппелин* – контексты его употребления в Ruscorpora.ru
- ...

Цеппелин

Цеппелин: МАС

- Дирижабль с металлическим каркасом, обтянутым тканью.
- *На черном небе выступала светло-желтая масса формы толстой сигары — цеппелин.* Игнатьев, Пятьдесят лет в строю.
- [По имени немецкого конструктора Ф. Цеппелина]
- отсутствует значение «овощное блюдо», ср.

Википедия:

- **Цеппелины** или **диджкукулиай** (лит. *Cepelinai, Didžkukuliai* 'диджкукулиай') — огромные клёцки из тёртого и/или варёного картофеля с начинкой из фарша (либо творога или других ингредиентов)...
- - отсутствует ссылка на названия ансамбля Лед Цеппелин, ср. Википедия:
- **Led Zeppelin** — британская рок-группа, образовавшаяся в сентябре 1968 года в Лондоне, Англия, и признанная одной из самых успешных, новаторских и влиятельных в современной истории...

Сочетаемость слова Цеппелин в контекстах

- значение 1: *дирижабль, полет, граф, долететь, подниматься, транспорт, воздушный, гигант, форма сигары, висеть*
- значение 2: *вилка, ковырять, теплый, вкусный, картофель, клецки, начинка, фарш*
- значение 3: *ансамбль, услышать, лед*

Параметры ДС

Размер контекстного окна различается

- в соответствии с целями исследования:
 - ✓ установление синтагматических связей –1-2 слова;
 - ✓ установление парадигматических связей — 5-10 слов;
 - ✓ установление тематических связей — 50 слов и больше.
- с объектами исследования:
 - ✓ ИГ ~ -4+4
 - ✓ ГГ ~ -3+5

Размерность векторного пространства (!)

Геометрия значения

- Сочетаемость слова в тексте можно представить в виде матриц совместной встречаемости, в виде векторов в n -мерном пространстве и т.д. Соседи слова в контексте – признаки, измерения в n -мерном пространстве.
- Идея контекстных векторов была предложена Ч. Осгудом: контексты, в которых встречались слова, выступали в качестве измерений векторов. В качестве таких контекстов использовались антонимические пары прилагательных (например, *быстрый-медленный*), для которых участники опроса выставляли оценки по семибалльной шкале.
- Пример пространства контекстных признаков, описывающего значение слов *мышь* и *крыса*:

	small-large	bald-furry	docile-dangerous
mouse	2	6	1
rat	2	6	4

Контекстный вектор

- Термин *контекстный вектор* был введен С. Галлантом для описания смысла слов и разрешения лексической неоднозначности: использовалось множество признаков, заданное исследователем, таких как *человек, мужчина, машина* и т. д.
- *Gallant S.* Context vector representations for document retrieval (англ.) // Proceedings of AAAI Workshop on Natural Language Text Retrieval : конференция. — 1991.
- Пример пространства контекстных признаков, описывающего значение слова *астронавт*:

	human	man	machine	politics	...
astronomer	+2	+1	-1	-1	...

Совместная встречаемость

(Jurafsky and Martin, 2008)

- apricot: { boil, large, sugar, water }
- pineapple: { boil, large, sugar, water }
- digital: { arts, data, function, summarized }
- information: { arts, data, function, summarized }

Table 2

Sample co-occurrence table used in the HAL method, prior to row length normalization.


	a	as	chuck	could	how	if	much	wood	woodch.	would	,	.	?	a	as	chuck	could	how	if	much	wood	woodch.	would	,	.	?
a	13	24	12	3	9	20	22	31	16	23	18	0	7	13	7	31	26	0	14	4	21	50	9	16	7	7
as	7	8	15	11	0	5	9	25	10	0	3	0	17	24	8	2	3	0	9	10	10	20	13	11	0	0
chuck	31	2	5	20	5	14	6	9	36	15	12	0	0	12	15	5	6	0	9	8	30	10	2	11	9	12
could	26	3	6	0	0	16	2	4	30	9	14	0	0	3	11	20	0	0	0	6	23	2	1	0	8	8
how	0	0	0	0	0	0	0	0	0	0	0	0	0	9	0	5	0	0	3	10	9	7	8	4	0	0
if	14	9	9	0	3	0	8	11	16	15	20	0	2	20	5	14	16	0	0	3	14	18	0	0	5	5
much	4	10	8	6	10	3	0	8	5	0	2	0	9	22	9	6	2	0	8	0	20	18	15	10	0	0
wood	21	10	30	23	9	14	20	7	26	5	11	0	8	31	25	9	4	0	11	8	7	26	20	14	10	10
woodch.	50	20	10	2	7	18	18	26	13	20	16	0	5	16	10	36	30	0	16	5	26	13	10	18	9	9
would	9	13	2	1	8	0	15	20	10	0	0	0	4	23	0	15	9	0	15	0	5	20	0	17	3	0
,	16	11	11	0	4	0	10	14	18	17	0	0	3	18	3	12	14	0	20	2	11	16	0	0	4	4
.	7	0	9	8	0	5	0	10	9	3	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
?	7	0	12	8	0	5	0	10	9	0	4	0	0	7	17	0	0	0	2	9	8	5	4	3	0	0

Матрица совместной встречаемости


	get	see	use	hear	eat	kill
knife	51	20	84	0	3	0
cat	52	58	4	4	6	26
dog	115	83	10	42	33	17
boat	59	39	23	4	0	0
cup	98	14	6	2	1	0
pig	12	17	3	2	9	27
banana	11	2	2	0	18	0

co-occurrence matrix **M**

Точки в двумерном пространстве



Вектора в двумерном пространстве




Меры расстояния


- Евклидово расстояние: $D(x,y) = \{ \sum_i (x_i - y_i)^2 \}^{1/2}$
- Квадрат евклидова расстояния: $D(x,y) = \sum_i (x_i - y_i)^2$
- Расстояние городских кварталов (манхэттенское расстояние) ~ мера Хэмминга: $D(x,y) = \sum_i |x_i - y_i|$
- Расстояние Чебышева: $D(x,y) = \text{Максимум}|x_i - y_i|$
- Степенное расстояние: $D(x,y) = (\sum_i |x_i - y_i|^p)^{1/p}$
- Процент несогласия: $D(x,y) = (\text{Количество } x_i \neq y_i) / i$
- Косинусная мера: где A и B — два вектора, расстояние между которыми вычисляется по формуле

$$\bullet \cos(A, B) = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

Кластеризация - дендрограмма



Кластеризация - визуализация



Методы уменьшения размерности векторных пространств

Удаление определенных измерений векторов в соответствии с лингвистическими или статистическими критериями:

- сингулярная декомпозиция Singular Vector Decomposition ;
- случайное индексирование Random Indexing.




Figure 1.2: The SVD decomposition of an $n \times d$ matrix.

Виды моделей ДС: LSA

- LSA = Latent Semantic Analysis (Landauer, Dumas et al.)
- корпус: 30 тыс. + статей из Academic American Encyclopaedia, 4,6 млн с/у
- матрица термы-документы для 60 тыс.+ слов
- логарифмы частот
- сокращение размерности признакового прост-ва до 300, SVD
- ...

Виды моделей ДС: Word Space

- Word Space (Schutze)
- Корпус – 60 млн с/у, New York Times News Service
- матрица термы-термы для 20 тыс. целевых слов и 2 тыс. контекстных соседей
- окно +/- 50 слов
- tf-idf
- сокращение размерности признакового пространства до 100, SVD

Виды моделей ДС: HAL

- HAL (Hyperspace Analogue to Language)
- корпус 160 млн с/у
- матрица термы-термы для 70 тыс. слов
- контекстное окно от ± 1 до ± 10

COALS

- Модификация HAL : COALS (Correlated occurrence analogue to lexical semantics)
- матрица размера $V \times V$ (где V - размер словаря),
- каждой ячейке соответствует частота совместной встречаемости двух слов в заданном окне,
- веса назначаются с учетом расстояния между словами,
- удаляются столбцы для редких слов,
- оставшиеся значения преобразуются в значения корреляции Пирсона между появлениями соответствующих слов, причём отрицательные значения заменяются на 0, а из положительных берётся квадратный корень,
- затем применяется сингулярное разложение матрицы, позволяющее использовать вектора слов небольшого размера.

Компьютерные инструменты ДС

- COALS <http://tedlab.mit.edu/~dr/>
- InfoMap <http://infomap-nlp.sourceforge.net/doc/algorithm.html>
- Google-Sets http://www.googleguide.com/favorite_sets.html
- SenseClusters <http://senseclusters.sourceforge.net/>
- LexSem <http://demo.patrickpantel.com/demos/lexsem/thesaurus.htm>
- Word Clusters <http://www.cs.ualberta.ca/~lindek/demos/wordcluster.htm>
- DISCO http://www.linguatools.de/disco/disco_en.html
- DSM <http://www.cs.cornell.edu/home/lee/papers/cf.home.html>
- www.aclweb.org/anthology/C04-1146.pdf
- JoBimText <http://ltmaggie.informatik.uni-hamburg.de/jobimtext/>
- SERELEX <http://serelex.cental.be/#queen>
- RDT https://nlp.ru/Russian_Distributional_Thesaurus
- RusVectores <https://rusvectors.org/ru/>
- WebVectors <http://vectors.nlpl.eu/explore/embeddings/en/>
- Ada-Gram <https://github.com/lopuhin/python-adagram/tree/master/adagram>

Word2Vec: что это?

- **Word2vec** – инструмент анализа текстов, основывающийся на векторном представлении слов.
- **Word2vec** был разработан группой исследователей Google в 2013 году.
- Работу над проектом возглавил Томас Миколов.
- <https://code.google.com/archive/p/word2vec/>
- Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient Estimation of Word Representations in Vector Space. In Proceedings of Workshop at ICLR, 2013
- Tomas Mikolov, Wen-tau Yih, and Geoffrey Zweig. Linguistic Regularities in Continuous Space Word Representations. In Proceedings of NAACL HLT, 2013.

Word2vec: принцип работы

- Word2Vec принимает на вход текстовый корпус, каждому слову приписывается вектор, координаты которого отражают статистику совместной встречаемости слов в корпусе.
- На основе векторных представлений создается словарь.
- Векторное представление слов отражает контекстную близость: слова, имеющие схожий смысл и встречающиеся в тексте рядом с одинаковыми словами, в векторном представлении будут иметь близкие координаты векторов.
- Полученные векторы могут быть использованы для обработки естественного языка и машинного обучения.


Word2vec не контекстная модель, решение принимается
безотносительно контекста

Алгоритмы обучения в Word2Vec


Способная предсказывать целевые замены для слова при том что
они не наблюдаются в исходных данных.

- Два основных алгоритма обучения в Word2Vec CBOW и Skip-gram — это нейросетевые архитектуры, которые описывают, как именно нейросеть «учится» на данных и «запоминает» представления слов.
- Принципы работы архитектур разные.
- ✓ Принцип работы CBOW — предсказывание слова при данном контексте (цель — описание парадигматических отношений),
- ✓ Принцип работы skip-gram — предсказывание контекста при данном слове (цель — описание синтагматических отношений).
- Пользователь имеет возможность выбрать нужный алгоритм.

CBOW и Skip-gram



CBOW



Skip-gram

CBOW и Skip-gram

- CBOW (Continuous Bag of Words) = «непрерывный мешок слов», модель, которая предсказывает текущее слово, исходя из окружающего его контекста с учетом четырех ближайших соседей термина (два предыдущих и два последующих слова) без учета порядка следования.
- Skip-gram использует текущее слово, чтобы предугадывать окружающие его слова. k-skip-n-gram — это последовательность длиной n, где элементы находятся на расстоянии не более, чем k друг от друга. Например, дано предложение *Я твой дом труба шатал*. Для этого предложения 1-skip-2-gram будет выглядеть, как набор биграмм («Я твой», «твой дом», «дом труба», «труба шатал») плюс следующие последовательности: *Я дом, твой труба, дом шатал* — то есть, пропускаем одно (1-skip) слово, а из оставшихся справа и слева от пропущенного делаем биграмм (2-gram).

Шаги работы Word2Vec

- Загружается корпус, рассчитывается встречаемость каждого слова в корпусе
- Массив слов сортируется по частоте (слова сохраняются в хэш-таблице), и удаляются редкие слова
- Строится дерево Хаффмана для кодирования словаря — это снижает вычислительную и временную сложность алгоритма.
- Из корпуса считывается субпредложение (sub-sentence) и проводится субсэмплирование наиболее частотных слов (sub-sampling).
- Субпредложение — это базовый элемент корпуса, обычно — просто предложение, но это может быть и абзац, например, или даже целая статья.
- Субсэмплирование — это процесс изъятия наиболее частотных слов из анализа, что ускоряет процесс обучения алгоритма и способствует увеличению качества получающейся модели.

Шаги работы Word2Vec

- Субпредложение обрабатывается окном, размер окна задается как параметр. Окно = максимальное расстояние между текущим и предсказываемым словом в предложении. Например, если окно равно трем, то для предложения «Я твой дом труба шатал» анализ будет проходит внутри блока в три слова — для «Я твой дом», «твой дом труба» и т.д. Окно по умолчанию равно пяти, рекомендуемым значением является десять.
- Применяется нейросеть прямого распространения (Feedforward Neural Network) с функцией активации иерархический софтмакс (Hierarchical Softmax) и/или негативное сэмплирование (Negative Sampling). Hierarchical softmax лучше при работе с не очень частотными словами, но медленнее, negative sampling лучше для частотных слов и дл векторов малой размерности (50...100), но он быстрее.

Негативное сэмплирование

- Задача Word2Vec: максимизация близости векторов слов (скалярное произведение векторов), которые появляются рядом друг с другом, и минимизация близости векторов слов, которые не появляются друг рядом с другом.

$$W_v \times W_c$$

$$\frac{W_v \times W_c}{\sum W_{c_i} \times W_v}$$

- $W_v \times W_c$ = близость целевого слова W_v и его контекстного соседа W_c
- $\sum W_{c_i} \times W_v$ = близость целевого слова W_v и всех прочих его контекстных соседей W_{c_i}
- Негативное сэмплирование — для сокращения объема вычислений. Принцип — мы не считаем ВСЕ возможные контексты, а выбираем случайным образом НЕСКОЛЬКО контекстов W_{c_i} .

RusVectōrēs:

дистрибутивные семантические модели для русского языка

- RusVectōrēs - это инструмент для исследования отношения между словами в дистрибутивных моделях.
<http://ling.go.mail.ru/dsm/ru/>
- RusVectōrēs = семантический калькулятор.
- В настоящий момент доступны 4 модели, обученные на разных корпусах (НКРЯ, НКРЯ + Википедия, новостной корпус, веб-корпус).
- Каждая модель содержит от 150 до 600 тысяч лемм.

RusVectōrēs: операции

- вычислять семантическое сходство между парами слов;
- находить слова, ближайšie к данному (с возможностью фильтрации по части речи);
- решать пропорцию вида "найти слово **X**, которое так относится к слову **Y**, как слово **A** относится к слову **B**";
- выполнять над векторами слов алгебраические операции (сложение, вычитание, поиск центра лексического кластера и расстояний до этого центра).
- рисовать семантические карты отношений между словами (это позволяет выявлять семантические кластеры);
- получать вектор (в виде массива чисел) и его визуализацию для данного слова в выбранной модели